GLOBAL SERVER

Higher mix of rack-level AI servers; Introducing 2028 forecasts

机架级 AI 服务器占比提升；发布 2028 年预测

17 April 2026 | 2:13AM HKT | Research | Equity| By Allen Chang and others

2026 年 4 月 17 日 | 香港时间凌晨 2:13 | 研究报告 | 股票 | 作者：Allen Chang 等

PDF Share Bookmark More

We raise our global servers TAM on a more positive outlook for AI server, and introduce 2028E estimates. We refresh our forecasts for (1) AI training servers - full rack / high power, (2) AI inferencing servers, (3) General servers, (4) HPC servers, and (5) leading US and China cloud capex. **We expect total Rack level AI server shipment (incl. Nvidia and AMD)** to reach 50k/ 90k in 2026E/27E (vs. 55k/ 80k in 2026, 27E previously), and we forecast 2028E shipments at 136k; the higher rack level forecast reflects our expectation that more Nvidia GPUs will be shipped in rack-level format to achieve more intense design and stronger GPU interconnection. **On ASIC AI servers,** we expect an accelerating ASIC adoption that leads ASICs to account for 43%/ 50%/ 55% of AI chips in 2026/27/28E, increasing their mix from our previous estimate of 40%/ 50% in 2026/27E (Read more). Our global AI server volume forecast implies demand for AI chips at 17m/ 22m/ 28m in 2026-28E (Exhibit 1), which increases from our last update due to our revised outlook on rack level and baseboard based AI servers across ASIC and GPU base. We forecast positive demand trend for GPU and ASIC platforms, and new AI servers based on new networking architectures from 2027 which will further enhance the advancement in computing performance.

基于对 AI 服务器更乐观的前景，我们上调了全球服务器市场总量（TAM）预测，并引入了 2028 年的预测数据。我们更新了以下领域的预测：(1) AI 训练服务器——整机柜/高功率，(2) AI 推理服务器，(3) 通用服务器，(4) HPC 服务器，以及 (5) 美国和中国领先云厂商的资本支出。我们预计整机柜 AI 服务器（包括 Nvidia 和 AMD）的总出货量在 2026/27 年将达到 5.0 万 / 9.0 万台（此前预测为 2026/27 年 5.5 万 / 8.0 万台），并预测 2028 年出货量为 13.6 万台；上调整机柜预测反映了我们的预期，即更多的 Nvidia GPU 将以整机柜形式出货，以实现更紧凑的设计和更强的 GPU 互联。在 ASIC AI 服务器方面，我们预计 ASIC 的采用将加速，导致 ASIC 在 2026/27/28 年占 AI 芯片的比例分别达到 43%/ 50%/ 55%，高于我们此前对 2026/27 年 40%/ 50% 的占比预测（阅读更多）。我们的全球 AI 服务器销量预测意味着 2026-28 年对 AI 芯片的需求将达到 1700 万/ 2200 万/ 2800 万颗（图表 1），这较我们上次更新有所增加，主要由于我们修正了对基于 ASIC 和 GPU 的整机柜及基板式 AI 服务器的前景展望。我们预测 GPU 和 ASIC 平台的需求趋势积极，且从 2027 年起，基于新网络架构的新型 AI 服务器将进一步提升计算性能的进步。

We expect the continuing AI infrastructure cycle to support growth through 2028E.

我们预计持续的 AI 基础设施周期将支持增长直至 2028 年。

AI servers: Buy Wiwynn / Wistron (ODM), Hon Hai / FII (ODM), LandMark (Silicon photonics), VPEC (Silicon photonics), AVC / Fositek (liquid cooling), Auras (liquid cooling), King Slide (rail kits), Chenbro (chassis), EMC (CCL), GCE (PCB), Innolight/ Eoptolink/ TFC Optical (Optical connections), TSMC (foundry; on CL), MPI (probe cards), WinWay (sockets), Aspeed (fabless), and Hon Precision (FT handler).

AI 服务器：买入 纬颖 / 纬创 (ODM)、鸿海 / 工业富联 (ODM)、联亚 (硅光子)、全新 (硅光子)、奇鋐 / 富世达 (液冷)、双鸿 (液冷)、川湖 (导轨)、勤诚 (机箱)、台光电 (CCL)、金像电 (PCB)、中际旭创 / 新易盛 / 天孚通信 (光连接)、台积电 (代工；列入确信买入名单)、旺硅 (探针卡)、颖崴 (测试座)、信骅 (无晶圆厂) 和 鸿劲 (FT 处理机)。

Exhibit 1: AI Server estimates: implied GPU vs. ASIC volume

图表 1：AI 服务器预测：隐含的 GPU 与 ASIC 出货量

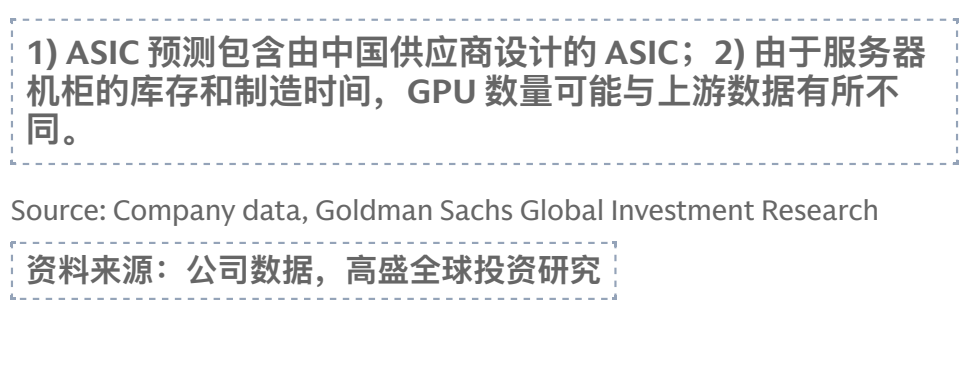

	2024	2025	2026E	2027E	2028E
AI server shipment (k units, 8-GPU equivalent)	**1,018**	**1,335**	**2,074**	**2,745**	**3,520**
Training (with 500 TFLOPS+ GPUs/ ASICs)	554	866	1,513	2,082	2,730
Training - High power	551	692	1,016	1,272	1,506
Training - Rack level	3	174	498	810	1,224
Inferencing	464	469	560	663	791
AI server shipment (k units, 8-GPU equivalent)	**1,018**	**1,335**	**2,074**	**2,745**	**3,520**
GPU	651	834	1,181	1,381	1,572
ASIC	367	502	893	1,364	1,948
Implied # of AI chips (Training and Inferencing) (k units)	**8,145**	**10,682**	**16,590**	**21,963**	**28,164**
GPU	5,205	6,670	9,447	11,050	12,576
ASIC	2,940	4,012	7,143	10,913	15,587
Mix	**100%**	**100%**	**100%**	**100%**	**100%**
GPU	64%	62%	57%	50%	45%
ASIC	36%	38%	43%	50%	55%

1) ASIC estimates include ASICs designed by Chinese suppliers; 2) GPU counts may differ from upstream data due to inventory and manufacturing time of server racks.

1) ASIC 预测包含由中国供应商设计的 ASIC；2) 由于服务器机柜的库存和制造时间，GPU 数量可能与上游数据有所不同。

Source: Company data, Goldman Sachs Global Investment Research

资料来源：公司数据，高盛全球投资研究

AI server updates: We increase our volume estimates for **high power AI servers** (i.e. powered by 500 TFlops+ ASIC and GPUs, such as H200, B200, etc.) by 7%/ 4% in 2026-27E and **inferencing AI servers** (e.g. powered by L40S, L20, ASICs, etc.) by 4%/ 1% in 2026-27E, supported by the increased cloud capex and the growing AI application usage globally.

AI 服务器更新：受全球云端资本支出增加和 AI 应用使用量增长的支撑，我们将 2026-27 年预测的高功率 AI 服务器（即由 500 TFlops+ ASIC 和 GPU 驱动，如 H200、B200 等）出货量分别上调 7%/ 4%，并将推理型 AI 服务器（如由 L40S、L20、ASIC 等驱动）出货量分别上调 4%/ 1%。

After GTC 2026, we see a diversifying choice of rack-level design for various use cases, as more AI chips are connected to achieve higher computing power and faster data transmission. We raise shipment volume estimates for **full rack AI servers** (e.g. powered by GB200, GB300, MI450 series etc.) to 55k/ 90k/ 136k racks (our outlook for AMD related AI racks is unchanged, while we raise the mix for Nvidia GPUs that are going to ship in rack-level form factor, Exhibit 4). With increasing AI server estimates, our implied AI chip forecast increases by 4%/ 5% to 17m/ 22m in 2026-27E, which we expect to reach 28m in 2028E (newly introduced).

在 2026 年 GTC 大会之后，随着更多 AI 芯片互联以实现更高的算力及更快的数据传输，我们看到针对各种应用场景的机架级设计选择日益多样化。我们将全机架 AI 服务器（例如搭载 GB200、GB300、MI450 系列等）的出货量预测上调至 5.5 万/ 9 万/ 13.6 万个机架（我们对 AMD 相关 AI 机架的展望保持不变，但提高了将以机架级形态出货的 Nvidia GPU 的占比，见图表 4）。随着 AI 服务器预测值的上调，我们隐含的 AI 芯片预测在 2026-27 预测年度分别上调 4%/ 5% 至 1700 万/ 2200 万颗，并预计在 2028 预测年度（新增预测）达到 2800 万颗。

CSP capex: Regarding customer spending, our US internet team forecasts that leading US cloud service providers (CSPs) in aggregate will grow their capex budgets by 63%/ 15%/ 10% YoY in 2026-28E (increased from 37%/ 15% YoY in 2026-27E in our last update in Jan). Within China internet space, we expect leading Chinese cloud platforms to grow capex by 42%/ 14%/ 10% YoY in 2026-28E (up from +17%/ +9% in 2026-27E previously)

CSP 资本支出：关于客户支出，我们的美国互联网团队预测，美国领先的云服务提供商（CSP）在 2026-28 预测年度的总资本支出预算将分别同比增长 63%/ 15%/ 10%（高于我们在 1 月份更新中预测的 2026-27 年度 37%/ 15% 的同比增幅）。在中国互联网领域，我们预计领先的中国云平台在 2026-28 预测年度的资本支出将同比增长 42%/ 14%/ 10%（高于此前预测的 2026-27 年度 +17%/ +9% 的增幅）。

Related reports: ***相关报告：***

Global Tech: PCs, smartphones, servers: Quantifying market opportunities (launching Global TAMs on Oct 3, 2023)

全球科技：PC、智能手机、服务器：量化市场机遇（2023 年 10 月 3 日发布全球市场总量预测）

Global Tech: Server TAM: Introducing rack-level AI server forecasts (Oct 29, 2024)

全球科技：服务器市场总量（TAM）：引入整机柜级 AI 服务器预测（2024 年 10 月 29 日）

Global Tech: Server TAM updates: AI server shipment timeframe recalibrating (Feb 9, 2025)

全球科技：服务器市场总量（TAM）更新：AI 服务器出货时间线重新校准（2025 年 2 月 9 日）

Global Tech: Server TAM updates: Revising down AI Training Server outlook (Mar 24, 2025)

全球科技：服务器市场总量（TAM）更新：下调 AI 训练服务器前景展望（2025 年 3 月 24 日）

Global Tech: ASIC AI server TAM introduced; Server TAM update and baseboard-based AI servers raised (June 28, 2025)

全球科技：引入 ASIC AI 服务器市场总量（TAM）；服务器市场总量更新及上调基板级 AI 服务器预测（2025 年 6 月 28 日）

Global Server: 2027E estimates introduced; Raising baseboard-based AI servers with rising ASIC penetration (Sep 27, 2025)

全球服务器：发布 2027 年预测；随着 ASIC 渗透率提升，上调基于基板的 AI 服务器预测（2025 年 9 月 27 日）

Global Server: ASIC servers expanding; AI full racks see diversifying chip platform (Jan 4, 2026)

全球服务器：ASIC 服务器持续扩张；AI 整机柜呈现多样化芯片平台趋势（2026 年 1 月 4 日）

Outlook for servers 服务器展望

- **AI training servers - expanding full rack estimates to include more form factors** (e.g. GB200/GB300/Vera Rubin in NVL72/NVL144 config. and MI450 series in Helios config.). Full rack AI servers shipments started in 4Q24 along with Nvidia's Blackwell platform, and we expect more AI servers to ship in full rack design from 2H26, including AMD's Helios rack as well as Nvidia's Oberon and Kyber rack.

  AI 训练服务器 —— 扩大整机柜预测范围，以纳入更多形态（例如：NVL72/NVL144 配置下的 GB200/GB300/Vera Rubin，以及 Helios 配置下的 MI450 系列）。整机柜 AI 服务器已随英伟达（Nvidia）Blackwell 平台于 2024 年第四季度开始出货，我们预计从 2026 年下半年起，将有更多 AI 服务器采用整机柜设计出货，包括 AMD 的 Helios 机柜以及英伟达的 Oberon 和 Kyber 机柜。

  We raise Nvidia full rack server shipment to 50k/ 77k/ 121k in 2026-28E, compared to 50k/ 67k in 2026-27E previously; We forecast AMD full rack server shipment to be at 5k/ 13k/ 15k in 2026-28E, compared to 5k/ 13k previously. This implies a TAM size of US$165bn/ 287bn/ 461bn in 2026-27E (vs. previously US$165bn/ 255bn for 2026-27E).

  我们将 Nvidia 整机柜服务器在 2026-28 预测年度的出货量上调至 5.0 万/ 7.7 万/ 12.1 万台，而此前对 2026-27 预测年度的预期为 5.0 万/ 6.7 万台；我们预测 AMD 整机柜服务器在 2026-28 预测年度的出货量将达到 0.5 万/ 1.3 万/ 1.5 万台，而此前预期为 0.5 万/ 1.3 万台。这意味着 2026-27 预测年度的市场总额（TAM）规模将达到 1,650 亿/ 2,870 亿/ 4,610 亿美元（此前对 2026-27 预测年度的预期为 1,650 亿/ 2,550 亿美元）。

- **AI training servers - high power in stronger ramp up** (e.g. H200/B200/B300 servers and ASIC AI servers, with single chip computing power >500 TFlops). Shipments should amount to 1.0m/ 1.3m/ 1.5m units in 2026-28E measured in 8-GPU equivalent, or +47%/ +25%/ +18% YoY (vs. previously 952k/ 1,227k in 2026-27E), with a TAM size of US$239bn/ 267bn/ 304bn (vs. previously US$205bn/ 251bn in 2026-27E).

  AI 训练服务器——高功耗产品增长势头更强（例如 H200/B200/B300 服务器和 ASIC AI 服务器，单芯片算力 >500 TFlops）。以 8-GPU 等效计算，2026-28 预测年度的出货量应达到 100 万/ 130 万/ 150 万台，同比分别增长 +47%/ +25%/ +18%（此前对 2026-27 预测年度的预期为 95.2 万/ 122.7 万台），市场总额（TAM）规模为 2,390 亿/ 2,670 亿/ 3,040 亿美元（此前对 2026-27 预测年度的预期为 2,050 亿/ 2,510 亿美元）。

  We are positive on the demand outlook for baseboard-based AI servers given their larger room for customization and lower budget burden for clients. The ramp up of high power ASIC chips also support our more positive view on the segment.

  鉴于基于基板（baseboard-based）的 AI 服务器具有更大的定制空间且客户预算负担较低，我们对其需求前景持乐观态度。高功耗 ASIC 芯片的放量也支持了我们对该细分市场更为积极的看法。

- **Inferencing servers to follow** (e.g. L40S/L20 servers and ASIC AI servers, with single chip computing power <500 TFlops). We expect shipments to increase to 560k/ 663k/ 791k in 2026-28E, or +19%/ +18%/ +19% YoY (vs. previously 539k/ 656k in 2026-27E), with a TAM size of US$39bn/ 51bn/ 67bn in 2026-28E vs. US$36bn/ 48bn in 2026-27E previously.

  推理服务器紧随其后（例如 L40S/L20 服务器和 ASIC AI 服务器，单芯片算力 <500 TFlops）。我们预计 2026-28 预测年度的出货量将增加至 56.0 万/ 66.3 万/ 79.1 万台，同比分别增长 +19%/ +18%/ +19%（此前对 2026-27 预测年度的预期为 53.9 万/ 65.6 万台），2026-28 预测年度的市场总额（TAM）规模为 390 亿/ 510 亿/ 670 亿美元，而此前对 2026-27 预测年度的预期为 360 亿/ 480 亿美元。

  We expect this growth to be driven by increasing applications.

  我们预计，应用场景的不断增加将推动这一增长。

- **General servers shipment to also grow.** We expect volumes to grow 4%/ 2%/ 3% YoY in 2026-28E and revenues to grow 15%/ 6%/ 6% YoY, supported by (1) increasing AI inferencing workload on general servers, and (2) rising ASP on increasing data processing needs driving product mix upgrade, and increasing memory price.

  通用服务器出货量也将增长。我们预计 2026-28 年的出货量将分别同比增长 4%/ 2%/ 3%，营收将分别同比增长 15%/ 6%/ 6%，这主要得益于：(1) 通用服务器上 AI 推理工作负载的增加；(2) 数据处理需求增长推动产品组合升级，以及内存价格上涨，共同带动了平均售价（ASP）的提升。

Servers: AI training server volume +75%/+38%/+31% in 2026-28E; General server volume +4%/ +2%/ +3% YoY

服务器：2026-28 年预测期内，AI 训练服务器出货量同比增长 +75%/+38%/+31%；通用服务器出货量同比增长 +4%/+2%/+3%

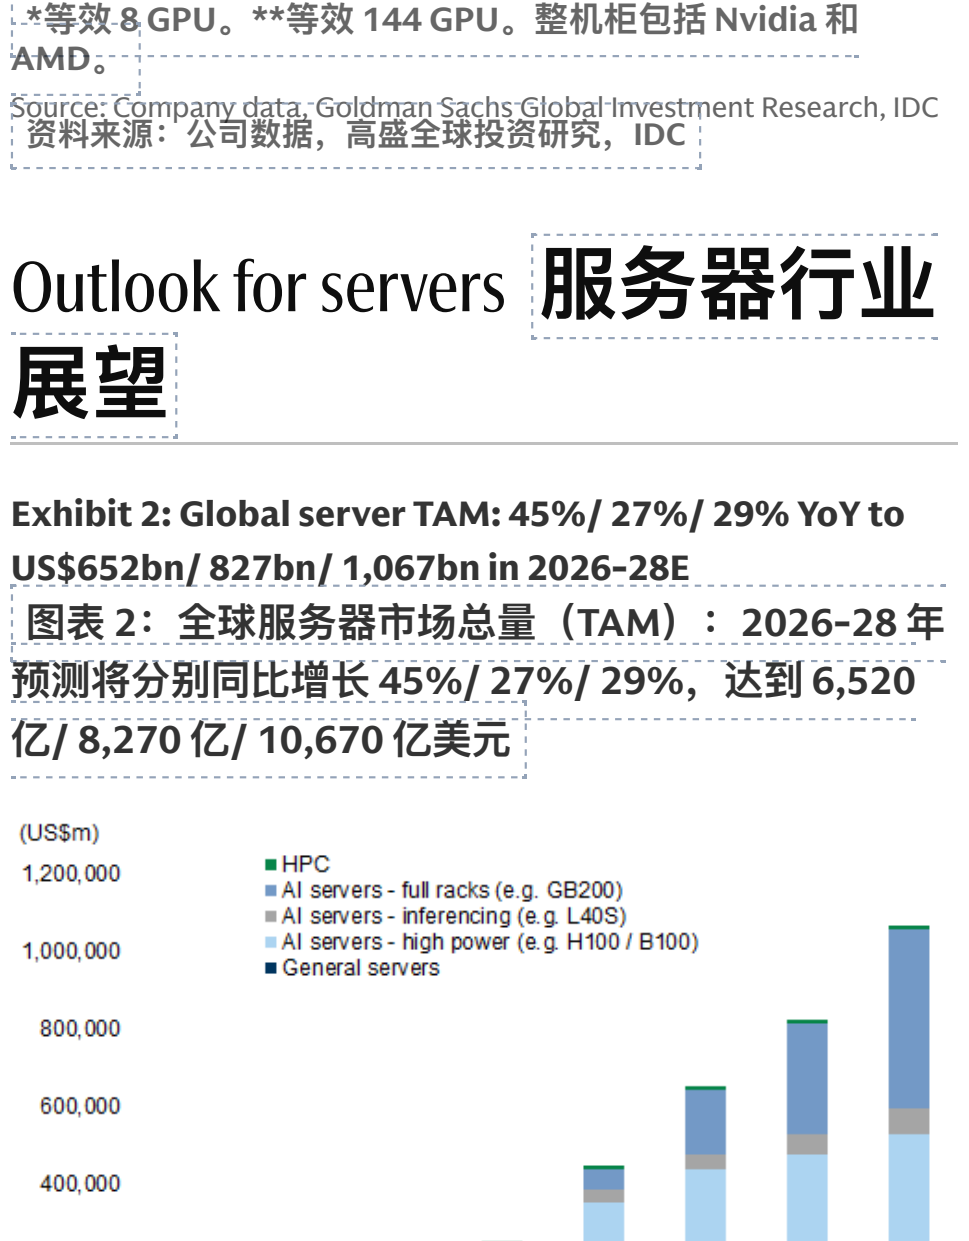

Global server market opportunity

*8 GPU equi. **144 GPU equi. Full racks include Nvidia and AMD.

*等效 8 GPU。**等效 144 GPU。整机柜包括 Nvidia 和 AMD。

Source: Company data, Goldman Sachs Global Investment Research, IDC

资料来源：公司数据，高盛全球投资研究，IDC

Outlook for servers 服务器行业展望

Exhibit 2: Global server TAM: 45%/ 27%/ 29% YoY to US$652bn/ 827bn/ 1,067bn in 2026-28E

图表 2：全球服务器市场总量（TAM）：2026-28 年预测期同比增长 45%/ 27%/ 29%，达到 6,520 亿/ 8,270 亿/ 10,670 亿美元

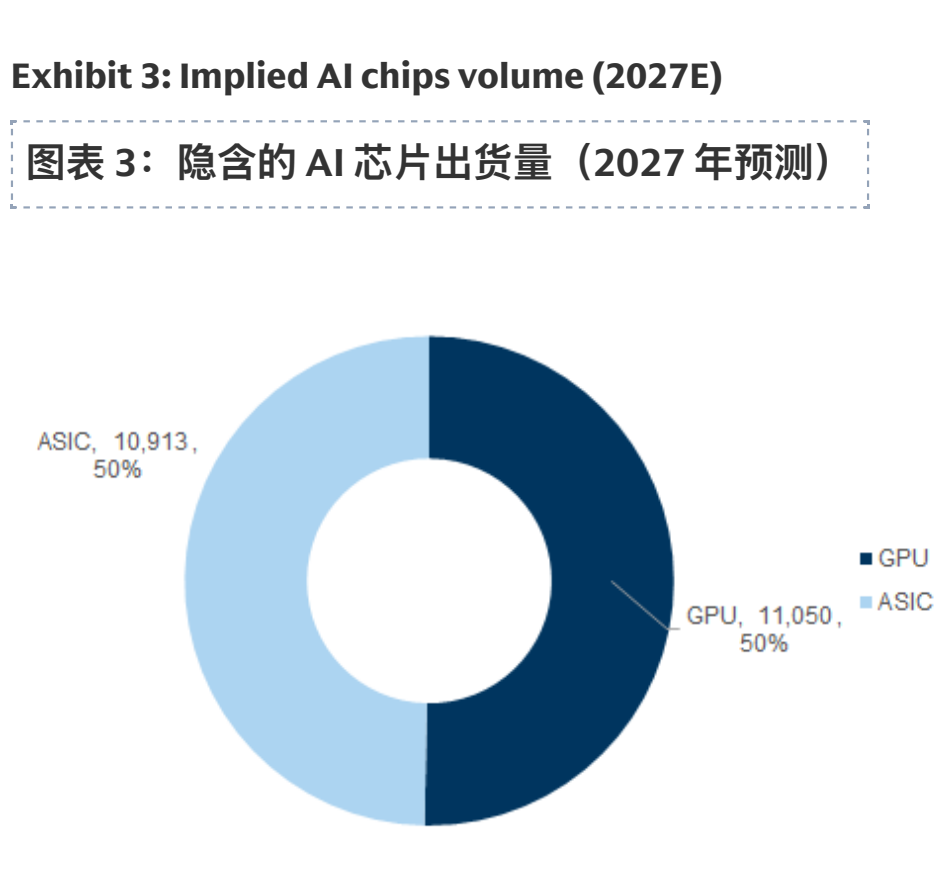

Source: Company data, Goldman Sachs Global Investment Research

资料来源：公司数据，高盛全球投资研究

Exhibit 3: Implied AI chips volume (2027E)

图表 3：隐含的 AI 芯片出货量（2027 年预测）

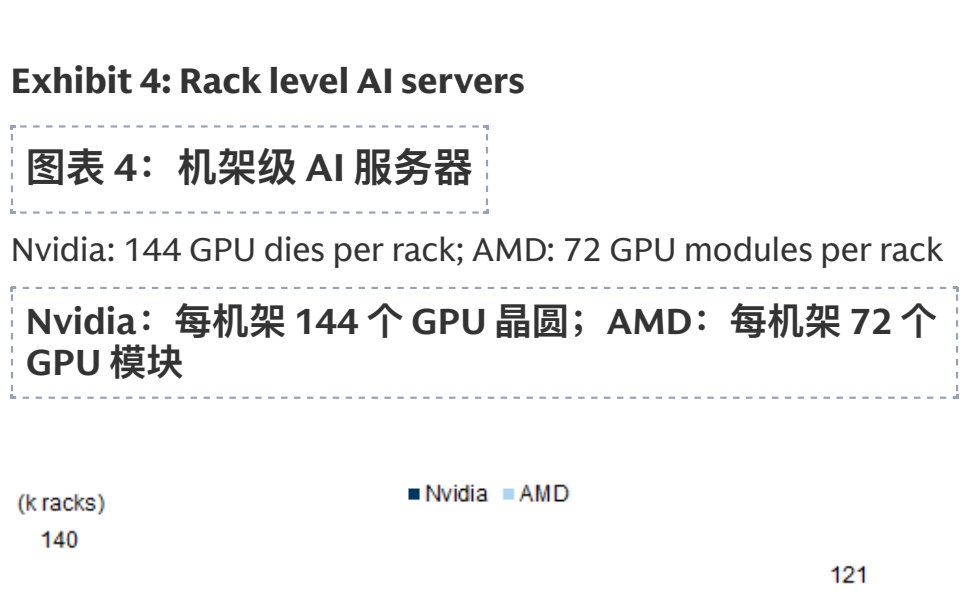

Source: Company data, Goldman Sachs Global Investment Research

资料来源：公司数据，高盛全球投资研究

Exhibit 4: Rack level AI servers

图表 4：机架级 AI 服务器

Nvidia: 144 GPU dies per rack; AMD: 72 GPU modules per rack

Nvidia：每机架 144 个 GPU 晶圆；AMD：每机架 72 个 GPU 模块

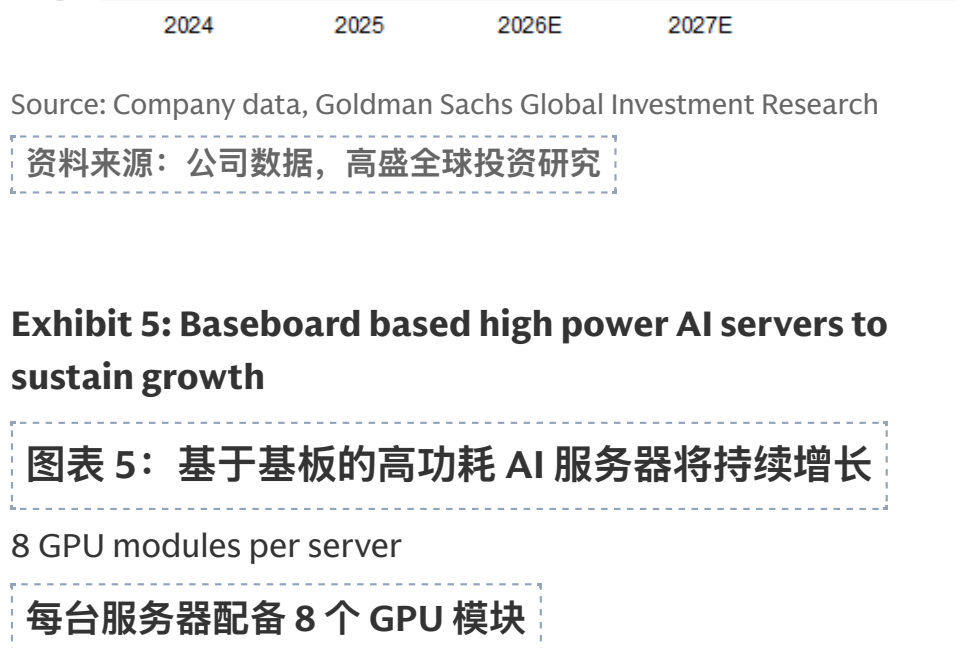

Source: Company data, Goldman Sachs Global Investment Research

资料来源：公司数据，高盛全球投资研究

Exhibit 5: Baseboard based high power AI servers to sustain growth

图表 5：基于基板的高功耗 AI 服务器将持续增长

8 GPU modules per server

每台服务器配备 8 个 GPU 模块

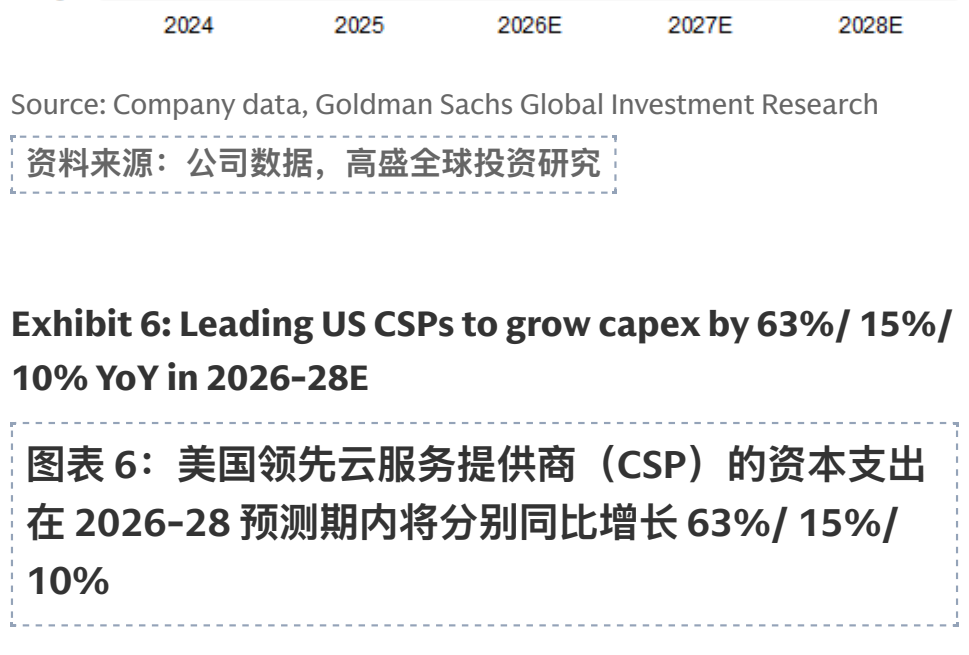

Source: Company data, Goldman Sachs Global Investment Research

资料来源：公司数据，高盛全球投资研究

Exhibit 6: Leading US CSPs to grow capex by 63%/ 15%/ 10% YoY in 2026-28E

图表 6：美国领先云服务提供商（CSP）的资本支出在 2026-28 预测期内将分别同比增长 63%/ 15%/ 10%

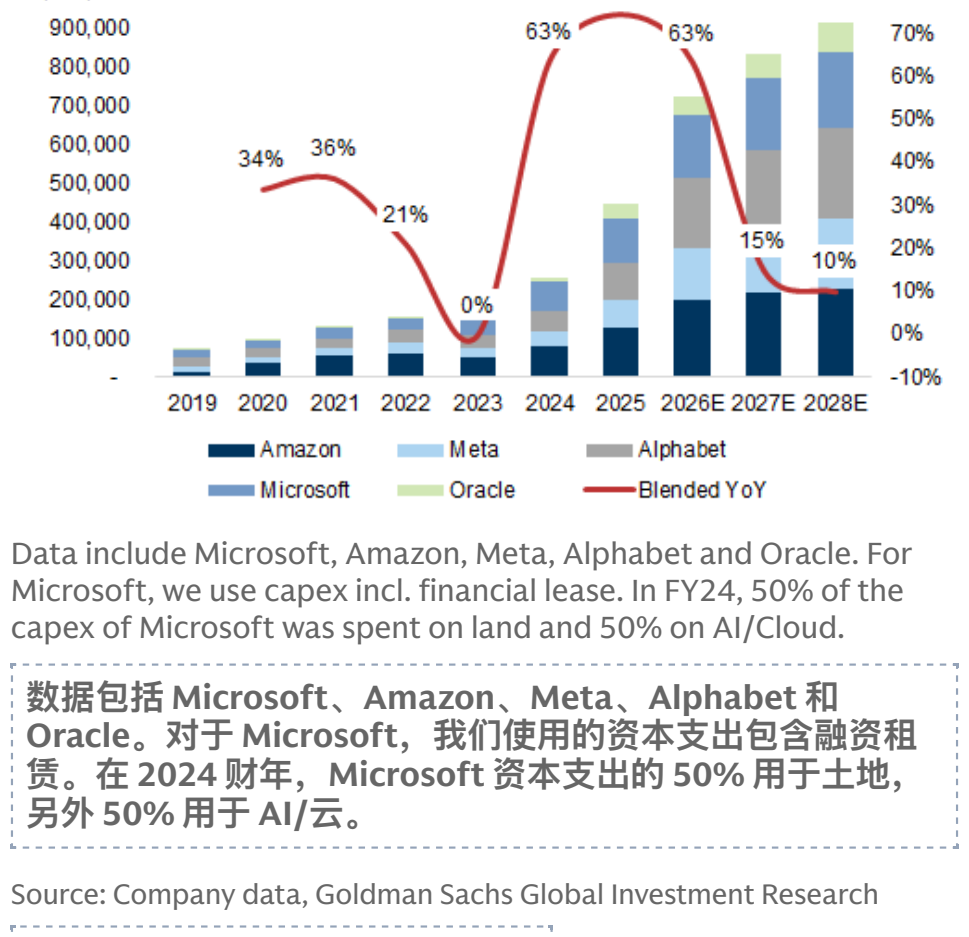

Data include Microsoft, Amazon, Meta, Alphabet and Oracle. For Microsoft, we use capex incl. financial lease. In FY24, 50% of the capex of Microsoft was spent on land and 50% on AI/Cloud.

数据包括 Microsoft、Amazon、Meta、Alphabet 和 Oracle。对于 Microsoft，我们使用的资本支出包含融资租赁。在 2024 财年，Microsoft 资本支出的 50% 用于土地，另外 50% 用于 AI/云。

Source: Company data, Goldman Sachs Global Investment Research

来源：公司数据，高盛全球投资研究

Exhibit 7: Leading China CSPs' capex +42%/ +14%/ 10% YoY in 2026-28E

图表 7：中国领先云服务商（CSP）的资本支出在 2026-28 年预计同比增长 42%/ 14%/ 10%

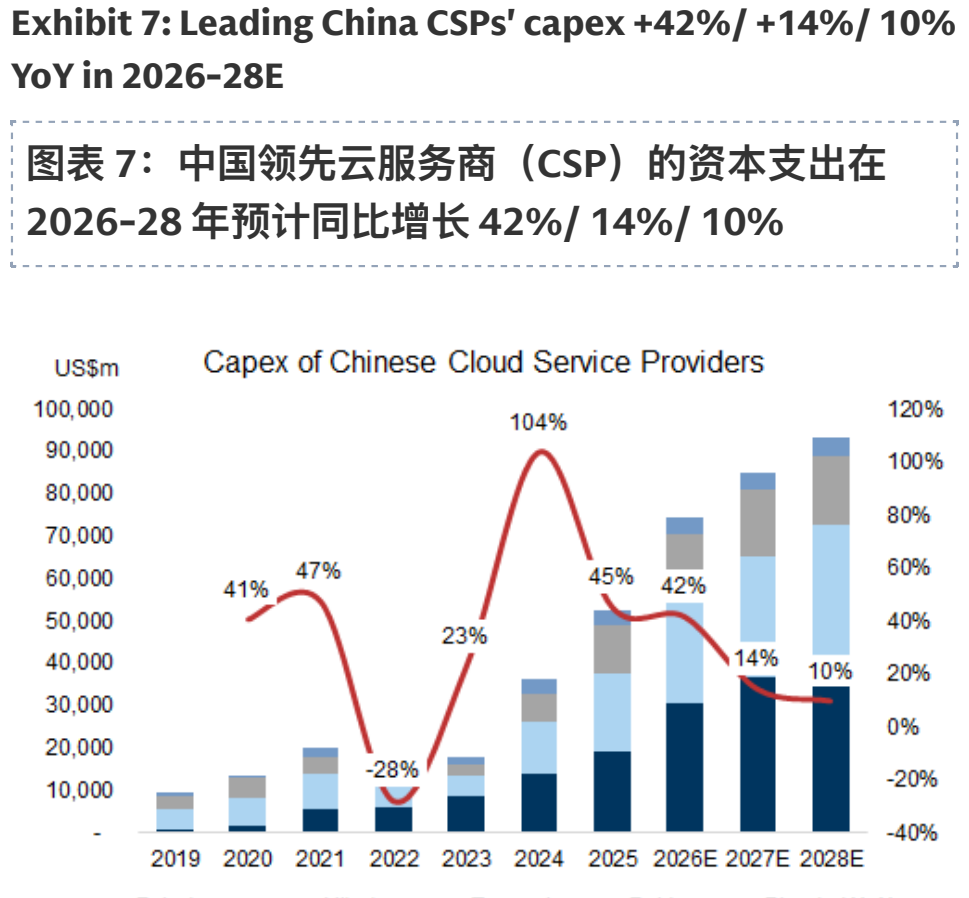

Data include Bytedance, Tencent, Alibaba, Baidu. We calculate Bytedance (private) relevant operating metrics by analyzing the industry and companies that our China Internet team cover, and then extrapolating them to Bytedance.

数据包括字节跳动、腾讯、阿里巴巴、百度。我们通过分析中国互联网团队覆盖的行业及公司，并将其推算至字节跳动，从而计算出字节跳动（私有公司）的相关运营指标。

Source: Company data, Goldman Sachs Global Investment Research

资料来源：公司数据，高盛全球投资研究

XXPQ **资讯群**

微信扫码加入圈子 >

R 小红圈